再生数估计中的不可约误差与监测设计

向导师汇报论文理论与第四轮修改

Apevon Science

Research & Intelligence

研究范围截至 2026 年 10 月 18 日

摘 要

这份说明是我写给老师的，用于当面讲解，也可以直接阅读。内容依次是论文《环境方差与报告异质性下再生数估计的不可约误差与监测设计》要回答的问题、理论主线及每条结论的成立条件、与 Parag 等 2022 年工作的关系、实证证据能支持到什么程度、第四轮如何回应老师的意见，以及需要老师决定的事项。文中命题、推论和式号均为终版编号，页码对应终版 PDF（正文 31 页，补充材料 11 页）。

关键词：再生数; 环境方差; 报告异质性; 方差平衡规模; 监测设计

目 录

1 我想回答的问题..... 6
2 理论主线..... 6
3 与 Parag 等 2022 年工作的关系..... 7
4 证据能支持到哪里..... 7
5 对老师意见的回应与第四轮修改..... 8
6 局限与需要老师决定的事..... 8
7 老师可能会问的问题..... 8

图目录

无

表目录

无

1 我想回答的问题

老师，这篇论文研究的是用病例报告数推断再生数时误差的结构。常见的做法默认监测覆盖越大，估计越准。我在单代负二项传播、二项报告的模型下证明，当关心的是跨期平均水平或下一期的增长时，误差中有一部分来自各期真实的环境波动和报告口径的波动，这部分与报告规模无关，扩大监测压不下去。这件事值得做，因为它决定了监测资源应当投在扩大覆盖、延长观测期还是统一报告口径上，而已有的信息量分析主要回答第一个问题。

2 理论主线

模型中 $m=\rho n$ 是预计报告规模，ρ 为报告率，k 为负二项离散参数。我把估计目标分成两个：估计目标 1 是当期的瞬时再生数 R_t，估计目标 2 是跨期均值 $\overline{R}$。命题 1（第 8 页）说明，对估计目标 1，C_t/m 在任意规模下都达到 Cramér–Rao 下界，Fisher 信息为 $I(R_t)=(m/R_t)(1+\rho R_t/k)^{-1}$。这是标准结果，我在论文里也按标准结果写。

论文的核心是命题 2（第 9 页）的式 (14)，即 $V(m)=v_R+A/m$，其中 v_R 是各期 R_t 的环境方差，$A=\overline{R}+\rho(\overline{R}^2+v_R)/k$。第二项是抽样误差，恰好等于 $E[1/I(R_t)]$，随规模下降；第一项与规模无关。这个结论有明确的适用范围，我在首次出现处都写了出来。它是对 R_t 条件无偏的估计量类中的最小均方误差。把它解释为一步前瞻预测的最小误差还需要 H4，即下一期 R_{t+1} 与过去信息独立，等价于 AR(1) 系数 $\varphi=0$。若 $\overline{R}$ 由 T_0 期数据估计，预测误差再乘以 $(1+1/T_0)$。$\varphi>0$ 时不可约部分降为 $(1-\varphi^2)v_R$（式 (6)、(7)，第 5 页），允许条件偏差的收缩估计也可以低于 v_R（补充材料 S1.11）。两项相等处的规模 $m_\times=A/v_R$ 我称为方差平衡规模，图示参数（$\overline{R}=1.15$、$v_R=0.04$、$k=0.35$、$\rho=0.25$）下为 53.1。规模低于它时扩大监测收益明显，高于它时收益迅速变小：规模翻倍使方差下降的比例在 $m=10$、53.1、200 时依次为 42.1%、25.0%、10.5%。

命题 4（第 12 页）让报告率 p_t 随期波动，并假设它与 R_t 独立（H5）。式 (20) 给出 $V_H=v_R+v_H+A_H/m$，其中 $v_H=\tau^2(\overline{R}^2+v_R)$，$\tau$ 是报告率的变异系数。v_H 同样与规模无关，所以不可约误差有环境和报告两个来源。$\tau=0.15$ 时 $v_H=0.0307$，平衡规模从 53.1 降到 30.4。三条杠杆由此而来：扩大规模只压低 A_H/m，增加期数压低均值的估计误差，只有统一报告口径能去掉 v_H。命题 6（第 14 页，式 (27)）在 $T=10$、$m=50$ 的基线下比较三者，规模扩大到 10 倍的效果不如期数增加到 4 倍；报告偏差在各期持续存在时，增加期数也无济于事。

设计部分从命题 3（第 10 页）开始。独立环境下成本最优规模为 $m^*=\sqrt{(c_0/c_1)m_\times}$（式 (17)），$c_0$ 和 c_1 分别是每期固定成本和单位报告成本，这与 Cochran 的两阶段抽样同构。命题 7（第 14 页）把它推广到 AR(1) 环境，式 (28)–(29) 给出预算阈值 $B^\dagger$：预算低于阈值时应选更少、更大的期，远高于阈值时才回到大预算近似。取 $c_0/c_1=100$，$\varphi=0.8$ 时阈值为 775；预算为 600 时整数最优是 $T=3$、$m=100$，模拟方差 0.0403，按大预算近似取 $T=5$、$m=20$ 则为 0.0504。

3 与 Parag 等 2022 年工作的关系

Parag、Donnelly 和 Zarebski 2022 年在 Nature Computational Science 的文章（论文文献 [15]）研究带噪声的流行曲线含有多少关于 R_t 的信息，其式 (15)（第 592 页）为 $F_C(R_t)=\rho_t F_{\tau-t}\Lambda_t/R_t$。我的模型没有报告延迟，取 $\Lambda_t=n$、$F=1$、$\rho_t=\rho$ 并令 $k\to\infty$，命题 1 的信息量就回到 m/R_t，与该式逐项一致。因此估计目标 1 这部分用的是标准工具，负二项下的 Fisher 信息也是已知结果，我不把它算作贡献。

他们的核心量是多期总信息与几何均值 $\theta=G(\rho)G(F)$（式 (5)，第 587 页），处理的是时变报告率与延迟。我的模型中 ρ 不随时间变、没有延迟，所以我不说推广了这两个量。两篇的条件也有差别：Parag 把报告率取为 Beta 分布，信息只依赖几何均值（第 586–588 页），对任意参数都有限；我在命题 4(iv) 观测报告率的情形下用到 $E(1/p_t)$，要求 $\rho v>1$，这是我的矩估计量带来的更强条件。他们在第 585 页同样假设各期 R_t 独立，并在第 591 页承认这一假设可能不成立，我把预测等价限定在 $\varphi=0$，与这一处理一致。

我认为论文真正新的结果有四项，上一轮审稿意见的评价是“新但初等”，我同意。推论 1（第 12 页，式 (24)）给出覆盖率与报告率边际效果的反转阈值：二项型波动下当 $m>\rho^2 v/k$ 时排序反转，$v=100$ 时阈值为 17.9；制度型波动下两者效果之比为 1.87，覆盖率始终占优，而两条途径都去不掉 v_H。命题 4(vi)（式 (23)）给出区分报告噪声与环境波动的截距比特征，纯报告噪声下 $q_1\in[0.883,1.338)$、$q_2\in[0.892,1.374)$。命题 5(iii)（第 13 页，式 (26)）给出 AR(1) 下估计 v_R 的有效期数 $T_{\text{eff}}\approx T(1-\varphi^2)/(1+\varphi^2)$，$\varphi=0.8$、$T=26$ 时只有 6.2 期；有限规模修正见补充材料 S1.7（第 35 页，式 (S18)–(S19)），$m=10$ 时一阶展开给出 11.9 倍而精确值为 37.5 倍，所以小规模时必须用精确式。第四项是命题 7 的预算阈值。

4 证据能支持到哪里

实证用美国国家医疗安全网络 16,218 个州周的流感住院数据，主分析为流行初期的 1,267 个州周。预测误差按 $a+b/D$ 随规模下降，截距 $a=0.0991$（百分位区间 0.0837–0.1165），隐含的平衡规模落在情景值 21.3–49.2 的范围内。

较强的证据有两条。第一条是截距超出量。截距比本身区分不了机制：日更新、$\varphi=0$ 的零假设带（108 格）和增长期带都与经验区间相交，单靠入院延迟就能产生 $q_1<1<q_2$，所以我把证据重心放在超出量上（表 3 在第 19 页，图 12 在第 22 页）。第二条是报告调整的等价检验：$\Delta a=-0.0004$，90% BCa 区间为 −0.0012 至 0.0005，落在 ±0.0050 的等价界内，区间上端只占超出量 0.0704 的 0.93%。这条结论只覆盖可由填报比例观测到的报告成分；报告率网格仿真显示，该判据看不到与填报比例无关的报告离散。

只到方向一致的证据需要分开看。七个病原与口径组合按预注册判据为复现 0、部分复现 4、方向一致 3；等价检验在 BCa 口径下 5/7 成立，正态近似下 3/7。独立数据中，ILINet 只给出同向的截距比，99.7% 的重抽满足 $q_1<1<q_2$，但病例定义不同；FluSurv-NET 区间太宽，没有信息；HHS Protect 与 NHSN 相关系数 0.995，只能作一致性核对。季层面分量也没有结论：$S=3$ 时随机效应估计为 0.077，区间宽 0.267，推论 2（第 14 页）表明三个季时相对标准误至少为 0.82。

5 对老师意见的回应与第四轮修改

老师之前提的五条意见我都改了。题目在第三轮换成了现在的题目。为去掉 AI 味，我建了主张与证据账本，删去比喻和空泛的连接句。格式参照 Parag 2022 与 Epidemics 范文调整。推导补全后证明移入补充材料 S1，正文第 9 页加了表 1 作为推导路线图。估计目标 A/B 改为估计目标 1/2。

第四轮的修改按优先级分四档。P0 修改措辞、补零假设带，并在首次使用处写明条件。P1 核对参考文献 DOI 并整理复现包，在空目录中按说明重跑，24,812 个数值 0 处不一致。P2 新增补充表 S1–S6。P3 拆分引言，把 9 个命题合并为 7 个，证明全部移到补充材料。

6 局限与需要老师决定的事

我自己清楚的局限有四处。理论假设 k 与 ρ 已知且没有报告延迟，H5 的独立性在第 28 页单独讨论过，实际数据未必满足。四项新结果都是初等推导。截距超出量的来源至今没有识别。篇幅上，引言至参考文献为 30 页，超出 28 页的目标；全文 16 张图，范文只有 5 张。

需要老师决定的有五件事。其一是目标期刊是否仍为 Epidemics，篇幅是否还要压缩。其二是代码与数据是否在 Zenodo 存档并取得 DOI，这需要作者账号。其三是资助声明，目前写的是“本研究未获得专项资助。”，请老师确认；重新分析中用了 AI 工具，使用声明的措辞也要按期刊政策定。其四是是否现在投稿。其五是后续工作：我打算把 anytime-valid 推断另做一篇；英文版和图的精简放到改投英文期刊时一并完成。

7 老师可能会问的问题

问 1：环境方差是模型假设出来的，凭什么说它不可约?

答：不可约是相对于估计量类说的。命题 2(v)（第 9 页）证明，在对 R_t 条件无偏的估计量中，最小均方误差就是式 (14)。允许偏差的收缩估计可以更低，补充材料 S1.11 给了例子：$m=50$ 时先验中心偏离 $\overline{R}$ 不超过 0.279，收缩估计的均方误差就低于 $v_R=0.04$。所以论文中凡说不可约，都带着这个条件。

问 2：和 Parag 的工作相比，是不是只把泊松换成了负二项?

答：换成负二项本身不算贡献，$k\to\infty$ 时命题 1 回到 Parag 式 (15)（第 592 页）。增量在于加入环境方差与报告异质性、区分两个估计目标，以及由此得到的设计结论，对应式 (14)、(20) 和命题 7。

问 3：实证能证明环境方差存在吗?

答：不能单独证明。截距比的零假设带与经验区间相交（表 3，第 19 页），能确定的是截距超出量远大于可观测报告成分所能解释的部分，等价检验区间上端只占超出量的 0.93%。超出量来自环境波动还是与填报比例无关的报告离散，现有数据分不开。

问 4：预算阈值对实际监测有什么用?

答：它回答该多设几期还是把每期做大。$\varphi=0.8$、预算为 600 时，按大预算近似取 $T=5$、$m=20$ 的方差为 0.0504，比整数最优的 0.0403 高约 25%（第 14 页，式 (28)–(29)）。用它需要先从历史数据估计 v_R 和 φ，而 v_R 本身估不准，精度下界见推论 2。

问 5：有效期数这个结果为什么重要?

答：$\varphi=0.8$ 时，26 期数据估计 v_R 的信息只相当于 6.2 个独立期，估计均值时为 2.9 期（式 (26)，第 13 页）。按周数计算样本量会高估精度。季层面的分量只有三四个季可用，精度更差，这也是第 4 节说季层面没有结论的原因。